

Caracterizarea sistemelor video de monitorizare și statistică a traficului

Stoica Viorel
Univ. Tehnică Gheorghe Asachi, Iași

Ursachi Octavian
Univ. Tehnică Gheorghe Asachi, Iași

Abstract—Folosirea camerelor video în contextul traficului aduce multe informații ce pot fi folosite în multe arii, precum detecția și prevenirea de accidente, aplicarea legii, analiza statistică a traficului pentru introducerea optimizărilor. Acest document explică necesarul de metode inovative în analiza de trafic în intersecții, unde numărul ridicat de accidente face multe victime în rândul participanților la trafic. Sunt prezentate metodele uzual folosite pentru extragerea informațiilor utile din imagini și interpretarea acestora. Se vor identifica factorii ce afectează achiziția de date, precum și modalități de mitigare a acestora.

I. INTRODUCERE

Sistemele video de înregistrare și monitorizare sunt des întâlnite la scară largă în industria automotivă. Camerele de trafic sunt adoptate la nivel global în înregistrarea numerelor de înmatriculare a mașinilor cu viteze peste limita legală. Aceste sisteme de achiziție au un mare potențial și în anticiparea și prevenirea accidentelor [1] prin intermediul statisticii. Monitorizarea traficului este cea mai folosită când este aplicată în intersecții, deoarece acestea prezintă cel mai ridicat risc de accidente rutiere [2]. Prin observarea comportamentului uzual al participanților la trafic în astfel de zone și recunoașterea anomaliilor, se pot detecta accidentele mult mai rapid, reducând timpul de răspuns al autorităților și salvând vieți. Siguranța în intersecții este o problemă critică la nivel mondial. Intersecțiile sunt deosebit de periculoase în comparație cu autostrăzile datorită arhitecturilor lor care introduc multe posibilități de eroare umană. Statistici de la Departamentul de Transport al SUA arată că între 1998 și 2007, numărul deceselor la intersecții a trecut de 90.000 [2]. Potrivit European Road Safety Observatory, peste 62.000 de oameni au murit în accidente la intersecții între 1997 și 2006. Mai recent, în UE, în 2013, peste 5.000 de persoane au murit în accidente rutiere la intersecții [2]. Condițiile meteo nu sunt o cauză majoră a deceselor la intersecții; acestea afectează în mod egal și celelalte zone. Cu toate acestea, condițiile de iluminare reprezintă un factor major deoarece aproape un sfert din decese la intersecții se întâmplă în timpul nopții. În general, indiferent de geometria intersecțiilor sau de condițiile meteorologice, eroarea umană rămâne cel mai important factor. Peste 80 din 100 de accidente din intersecții sunt cauzate de eroare umană. Pentru a reduce semnificativ numărul de decese cauzat de accidente rutiere în intersecții, este necesară dezvoltarea de sisteme inovatoare de monitorizare a vehiculelor specializate pentru intersecții.

II. ACHIZIȚIA DE DATE

A. Senzori și camere

Camerele video sunt un element de bază în orice sistem de urmărire, permițând o analiză în timp real amănunțită. Obiectele sunt vizibile cu camera din cauza reflexiei luminii de la suprafața lor pe senzor. Pentru operațiuni la lumina zilei, pot fi folosite camere în spectrul luminii vizibile. Totuși, noaptea sau în vreme dificilă, o cameră în spectrul vizibil este puțin probabil să aibă performanțe suficient de bune. Utilizarea camerelor termice sau în spectru infraroșu pot fi o soluție bună pentru vederea pe timp de noapte în locuri slab iluminate, pe vreme rea sau ceață.

B. Furnizarea seturilor de date

Interesul pentru monitorizarea traficului din intersecții este în creștere continuă. Acest lucru a dus la apariția unor seturi de date provocatoare pentru evaluare și benchmarking. Dacă se dorește antrenarea pe un set restrâns de date, există acces facil la o multitudine de videoclipuri preînregistrate pe platformele majore de distribuire de conținut. Pentru antrenarea unei rețele neuronale, sau aplicarea unor algoritmi mai avansați, se pot folosi capturi în timp real de la o multitudine de camere ce înregistrează 24/7 de pe aceleași platforme.



Fig. 1. Coldwater Michigan 4 way intersection

III. GENERALITĂȚI ALE DETECȚIEI DE VEHICULE

Există mai multe provocări în ceea ce privește detecția vehiculelor prin intermediul camerelor. În primul rând, calitatea senzorului camerei limitează rezoluția imaginilor de intrare. În plus, există inițializări, pași importanți (calibrarea camerei, definirea regiunii de interes) care sunt unici pentru fiecare set de date.

A. Detectia și urmărirea vehiculelor

Vehiculele au caracteristici ce diferă mult, precum dimensiunea, culoarea și forma. Un pas important este alegerea unei reprezentări adecvate și robuste a caracteristicilor vehiculului pentru aplicația aleasă (blobs, set de puncte sau modele geometrice[4]). În general, reprezentarea vehiculului definește strategie de urmărire. Cel mai important lucru este capacitatea de a menține vehiculele urmărite cât mai mult posibil în cadrul imaginii. Urmărirea fiabilă a vehiculelor este esențială, deoarece va permite ulterior analiza traiectoriilor și recunoașterea comportamentelor lor. Detectarea vehiculului și urmărirea sunt sarcini oarecum legate. Unele metode necesită vehiculul să fie mai întâi detectat și apoi urmărit, în timp ce alte strategii folosesc urmele vehiculelor ca indicii pentru detecție. Sunt mai multe probleme care fac ca detecția și urmărirea vehiculelor să fie dificilă. Principalele provocări sunt:

- ocluzia vehiculului(vehicul-vehicul, clădiri-vehicul)
- modificarea percepției asupra lui (aspect, plasarea camerei, distorsiune, dimensiune, distanță)
- mișcare bruscă a vehiculului sau schimbare bruscă în mediu (iluminare, vreme, vedere pe timp de noapte)
- detectarea și eliminarea umbrelor

B. Localizarea vehiculelor

Localizarea candidaților de vehicule poate necesita unul sau mai multe frame-uri. Diferitele metode pot fi clasificate în patru categorii: background subtraction, model-based segmentation, feature-based segmentation, motion-based segmentation.

- Background subtraction: constă în extragerea obiectelor de fundal dintr-o singură imagine prin eliminarea unei referințe de fundal. Diferența majoră între abordările de scădere de fond din literatură se află în modalitatea de a obține fundalul. Estimarea de fond poate fi statică, dinamică, statistică sau adaptivă. Sunt mai multe probleme legate de această metodă, din cauza dificultății aferente de a defini granițele dintre fundal și prim-plan [5]. Cea mai populară metodă de modelare a fundalului este Gaussian Mixture Model (GMM). Constă în a modela valorile pixelilor în timp printr-un amestec ponderat de gaussian.
- Model-based segmentation: constă în identificarea posibilelor vehicule din prim plan într-o imagine prin compararea vehiculului cu forme predefinite sau proiectate 2D sau 3D în regiunile imaginii, fără a cunoaște modelul fundalului. Aceste abordări de potrivire directă sunt nerealiste pentru că este imposibil să ai un model pentru toate vehiculele posibile care pot apărea în scenă.
- Feature-based segmentation: are la bază analiza geometriei sau caracteristicile aspectului pentru localizarea candidatului în prim-plan. Se pot folosi textura, culoarea , umbra și elemente geometrice precum colțurile și simetrie sau fuziunea mai multor indicii. Un bun algoritm ar trebui să poată surprinde caracteristicile distinctive și să fie suficient de robust la variații mici peste diferite condiții de fond [3]. Acest lucru este necesar pentru a reduce atât zgomotul de la intrare dar și timpul de calcul.

- Motion-based segmentation: constă în identificarea mișcării elementelor din prim-plan, căutând regiuni ale imaginii ce au modificări semnificative între cadre succesive. Aceasta folosește diferența de nivel de pixel și informațiile temporale pentru a extrage regiuni în mișcare. Generarea de ipoteze bazate pe mișcare folosește informații temporale pentru a detecta vehicule și obstacole prin potrivirea și gruparea pixelilor imaginii având aceleași caracteristici de mișcare pe cadre consecutive. Aceasta se poate adapta rapid la medii dinamice atunci când modificările temporale sunt importante, dar poate eșua în extragerea tuturor pixelilor reprezentativi în scene complexe. Mai mult, generarea deplasării vectorului pentru fiecare pixel consumă mult timp de calcul. Discretizarea imaginii dă rezultate mai bune și permite procesarea în timp real [6].

C. Urmărirea vehiculelor

Există mai multe abordări pentru urmărirea vehiculelor. În funcție de reprezentarea vehiculului care variază de la nivel de pixel la nivel de obiect, patru abordările generale pot fi distinse: region-based tracking, contour-based tracking, feature-based tracking, model-based tracking.

- region-based tracking: regiunile sau bloburile pot fi definite ca părți de imagine conectate cu proprietăți distinctive comune, cum ar fi statisticile de intensitate, culoare sau textură. Ea are ca scop urmărirea vehiculelor în funcție de variațiile regiunilor imaginii. O regiune întreagă asociată unui anumit vehicul este urmărită în timp folosind aspectul, proprietățile geometrice, precum și indicațiile de mișcare. Urmărirea pe regiuni este eficientă din punct de vedere computațional și funcționează bine în traficul liber. Cu toate acestea, sub trafic aglomerat condiții, deformare complexă sau un fundal aglomerat, vehiculele se pot bloca parțial unele pe altele în loc să fie izolate spațial [3].
- Contour based tracking: algoritmi de urmărire bazate pe contururi reprezintă obiecte după contururile lor, care sunt pur și simplu limita lor și actualizează aceste contururi în mod dinamic la fiecare increment de timp. De fapt, schimbări puternice în intensitatea imaginii apar în general la contururi, ceea ce îl face potrivit pentru scopuri de urmărire. Algoritmi de urmărire bazați pe contur oferă o descriere mai eficientă a vehiculelor decât algoritmi bazați pe regiune prin reducerea timpului de calcul și a complexității. Totuși, urmărirea bazată pe contur nu rezolvă perfect ocluziile. Chiar dacă contururile vehiculului pot fi extrase separat, sarcina dificilă este de a izola vehiculele care sunt urmărite dacă contururile diferitelor vehicule sunt fuzionate la un moment dat.
- Feature based tracking: urmărirea bazată pe caracteristici are la bază principiul că vehiculele pot fi reprezentate printr-un set de caracteristici, în loc de un obiect întreg. Aceasta se referă la gruparea metodelor care efectuează urmărirea prin extragerea mai întâi a caracteristicilor în imagini independente și apoi potrivirea caracteristicilor

peste imagini. Caracteristicile pot fi selectate ca părți reprezentative vehiculului, cum ar fi colțuri, linii, forme tipice. Această tehnică este eficientă atâta timp cât caracteristicile selectate sunt suficient de robuste și pot fi distinse chiar dacă vehiculul este parțial acoperit la un moment dat al secvenței. Urmărirea bazată pe caracteristici este potrivită pentru lumina zilei, de dimineață sau de noapte, precum și trafic de diferite intensități. Dar, deoarece un vehicul poate avea mai multe caracteristici, problema majoră constă în definirea condițiilor care să permită gruparea adecvată sau gruparea acelor caracteristici dintr-un vehicul dat. Algoritmii bazați pe caracteristici pot să se adapteze cu succes și rapid, permițând procesarea în timp real și urmărirea mai multor vehicule în trafic dens. În plus, pentru ca o abordare de urmărire bazată pe caracteristici să fie fiabilă, trebuie minimizat riscul nepotrivirilor printr algoritmi robuști de estimare.

IV. PARTICULARITĂȚILE INTERSECȚIILOR

Monitorizarea vehiculelor în intersecții este deosebit de dificilă din mai multe motive. Vehiculele trebuie detectate și urmărite din multe puncte de intrare în cadru. Mai mult, este necesar ca vehiculele să fie vizibile de la o distanță relativ lungă, nu doar când ajung exact la intersecție; ceea ce nu este întotdeauna posibil cu camerele tradiționale de supraveghere. Complexitatea monitorizării vehiculelor la intersecții este amplificată și din cauza posibilității mișcărilor haotice ale vehiculului. Spre deosebire de autostrăzi, vehiculele la intersecții pot avea mișcări variabile, bruște. Prin urmare urmărirea vehiculelor, predicția traiectoriei, precum și învățarea modelelor de mișcare în acest context rămân provocatoare și sunt în continuare probleme deschise. Multe abordări de urmărire pentru monitorizarea intersecțiilor sunt bazate pe regiune și presupun mișcări previzibile ale vehiculului. Abordările bazate pe caracteristici pot fi folosite pentru a gestiona parțial ocluziile în intersecții [3]. Cu toate acestea, dificultățile de caracteristici de grupare (supragrupare), mai ales la distanțe îndepărtate de la cameră, pot introduce erori semnificative în timpul urmăririi vehiculului. Unele sisteme de monitorizare a intersecțiilor sunt destinate să clasifice participanții la trafic în diferite categorii. Totuși, scopul majorității sistemelor de monitorizare a intersecțiilor este să analizeze interacțiunile dintre vehicule pentru a detecta evenimente anormale și a preveni accidente. În general, un potențial accident sau coliziune este definit atunci când dacă viteza sau direcția a două mașini nu se vor schimba, se vor ciocni”. Astfel, un algoritm robust de detectare a evenimentelor trebuie să fie independent de factorii geometrici, cum ar fi geometria intersecției, unghiul camerei video și poziția în care s-a produs accidentul [2].

REFERENCES

- [1] Seung Heon Han, Seog Chae, Jaehan Park, Syed Ali Hassan, Tariq Rahim and Soo Young Shin, "Video-Based Traffic Accident Prevention Safety System Using Deep Learning", The Journal of Korean Institute of Communications and Information Sciences vol. 45(8) pp. 1399-1406, August 2020
- [2] Stéphanie Lefèvre, Christian Laugier, and Javier Ibañez-Guzmán. "Risk assessment at road intersections: Comparing intention and expectation." In *Intelligent Vehicles Symposium (IV)*, 2012 IEEE, pp. 165–171. ,IEEE , 2012.
- [3] Sayanan Sivaraman and Mohan Manubhai Trivedi. "Looking at vehicles on the road : A survey of vision-based vehicle detection , tracking and behavior analysis. *Intelligent Transportation Systems*", 14(4), pp. 1773–1795, IEEE Transactions on 14.4 (2013), pp. 1773-1795.
- [4] Brendan Tran Morris and Mohan Manubhai Trivedi. "A survey of vision-based trajectory learning and analysis for surveillance." *Circuits and Systems for Video Technology*, IEEE Transactions on, 18(8):, pp. 1114–1127, 2008
- [5] Brendan Tran Morris and Mohan Manubhai Trivedi. "Understanding vehicular traffic behavior from video: a survey of unsupervised approaches." *Journal of Electronic Imaging*, 2013
- [6] Richard J Radke."A survey of distributed computer vision algorithms." In *Handbook of Ambient Intelligence and Smart Environments*, pp. 35–55. Springer, 2010